

INFORME - TAREA 1

BME513 - Inteligencia Artificial en Salud

Modelos lineales para regresión y clasificación

Autor Sebastian Inostroza Hurtado – Alumno DCIS 2026

1- Introducción


Contexto del Problema e información base disponible.

Este problema se contextualiza en la detección temprana de patologías isquémicas.

En el ámbito de la medicina de urgencias, la clasificación precisa del estado de un paciente es vital. Se busca, entonces, clasificar a los pacientes en tres categorías: sano, riesgo moderado e isquemia crítica.

En este escenario clínico, el costo de los errores es asimétrico. Un falso negativo (clasificar a un paciente con isquemia crítica como sano) es extremadamente grave, ya que priva al paciente de una intervención inmediata que podría salvarle la vida. Por el contrario, un falso positivo (clasificar a un paciente sano como de riesgo moderado) conlleva un costo menor, asociado principalmente a pruebas diagnósticas adicionales y estrés innecesario, pero sin poner en riesgo su vida. Además, la prevalencia de la enfermedad en la población es baja, lo que genera un dataset desbalanceado donde la clase de mayor interés es la menos frecuente.

En este ejercicio, resolveremos un problema de clasificación que posee desbalance de clases y costo asimétrico. Trabajaremos con datos simulados y compararemos variantes de los algoritmos vistos en clases. El siguiente ejemplo genera datos 2D:



2 – Generación del Dataset sintético.

Para este ejercicio, debe generar un dataset sintético como el anterior que replique las características del entorno médico real. En el código de ejemplo, note que se generan datos 2D; en la práctica real se usan atributos elegidos “a mano” de acuerdo al conocimiento de expertos y la experiencia. Para este ejercicio, nos restringiremos a un conjunto de biomarcadores y factores de riesgo que permiten diferenciar los niveles de gravedad. Estos atributos han sido seleccionados para que el modelo tenga que lidiar con diferentes escalas, distribuciones y tipos de datos. Los atributos a considerar son:

Nombre del atributo	Significado	Tipo de variable	Naturaleza de los datos	Rangos típicos
Troponina_T	Proteína liberada por daño miocárdico. Clave para detectar isquemia crítica .	Continua	Valores positivos con alto solapamiento.	Normal: < 14 ng/L Riesgo: 14 - 50 ng/L Isquemia: > 50 ng/L
Presion_Arterial	Presión sistólica medida en mmHg.	Continua	Distribución normal. Ayuda a distinguir crisis.	Baja: < 90 Normal: 120 Crisis: > 180
Fibrilación_V	Arritmias graves detectadas por el ECG al ingreso.	Binaria	Crucial para la clase isquemia crítica .	0: Ausente 1: Presente
Diabetes	Antecedentes previos de diabetes mellitus.	Binaria	Factor de riesgo que aumenta la probabilidad de enfermedad.	0: No tiene 1: Tiene
Tipo_Dolor	Clasificación del dolor torácico (Angina típica, atípica, etc.).	Categorica	Requiere One-Hot Encoding para el modelo.	1: No anginoso 2: Dolor atípico 3: Angina inestable 4: Angina típica
Edad	Edad cronológica del paciente.	Continua	Correlacionada con la severidad del desbalance.	Rango: 18 - 95 años

Resultado

Para este trabajo se generó un dataset sintético orientado a representar un escenario clínico de urgencias, en el cual los pacientes deben ser clasificados en tres categorías diagnósticas: **sano**, **riesgo moderado** e **isquemia crítica**. A diferencia del ejemplo inicial en dos dimensiones, en esta implementación se construyó un conjunto de datos con múltiples atributos seleccionados manualmente, siguiendo una lógica clínica y respetando la indicación de incluir variables de distinta naturaleza, escala y distribución.

El dataset fue diseñado para que el modelo enfrentara un problema más realista, integrando variables continuas, binarias y categóricas. En particular, se incorporaron seis atributos: **Troponina T**, **Presión Arterial**, **Fibrilación Ventricular**, **Diabetes**, **Tipo de Dolor** y **Edad**. La

variable objetivo quedó definida en tres clases: 0 = sano, 1 = riesgo moderado y 2 = isquemia crítica.

La construcción del dataset mantuvo además una condición clave del problema clínico: el **desbalance de clases**. En la simulación se estableció una distribución aproximada de **80% de pacientes sanos, 15% de pacientes en riesgo moderado y 5% de pacientes con isquemia crítica**, con el fin de reflejar un escenario donde la clase más importante desde el punto de vista médico es también la menos frecuente. Esta decisión es relevante, porque obliga a que los modelos no solo clasifiquen bien en promedio, sino que sean capaces de detectar adecuadamente los casos graves a pesar de su baja prevalencia.

Como se mencionó anteriormente el dataset sintético incluyó seis variables clínicas: **Troponina T, Presión Arterial, Fibrilación Ventricular, Diabetes, Tipo de Dolor y Edad**. Troponina T y Presión Arterial se modelaron como variables continuas asociadas al nivel de gravedad; Fibrilación Ventricular y Diabetes se incorporaron como variables binarias de riesgo; Tipo de Dolor se definió como variable categórica y posteriormente se transformó mediante One-Hot Encoding; y Edad se incluyó como una variable continua relacionada con el riesgo clínico general. En conjunto, estas variables permitieron representar un problema con diferentes escalas, tipos de datos y señales clínicas relevantes para la clasificación.

Tabla resumen variables del dataset creado:

<i>Variable</i>	<i>Tipo</i>	<i>Descripción en la simulación</i>	<i>Rol clínico esperado</i>
<i>Troponina_T</i>	Continua	Generada con distribuciones distintas por clase: baja en sanos, intermedia en riesgo y alta en isquemia	Biomarcador principal de daño miocárdico y señal dominante de isquemia crítica
<i>Presion_Arterial</i>	Continua	Generada con medias crecientes según severidad clínica	Indicador de inestabilidad hemodinámica y apoyo para distinguir crisis
<i>Fibrilacion_V</i>	Binaria	Simulada como presencia/ausencia de arritmia grave, con mayor frecuencia en isquemia crítica	Señal asociada a cuadros severos
<i>Diabetes</i>	Binaria	Simulada como antecedente clínico con mayor probabilidad en clases más graves	Factor de riesgo basal
<i>Tipo_Dolor</i>	Categórica	Definida en 4 categorías y luego transformada mediante One-Hot Encoding	Caracteriza la presentación clínica del dolor torácico
<i>Edad</i>	Continua	Generada con medias crecientes según severidad y acotada entre 18 y 95 años	Factor de riesgo general asociado a gravedad

Tabla 1 Variables clínicas utilizadas en la construcción del dataset sintético




Figura 1 Distribución de pacientes por clase en el dataset sintético




Figura 2 Proyección del dataset sintético en el plano Troponina T–Presión Arterial

3. Preparación y preprocesamiento de los datos

Una vez generado el dataset sintético, se prepararon los datos para el entrenamiento de los modelos. En primer lugar, se separaron las variables predictoras X de la variable objetivo y , correspondiente a las tres clases diagnósticas: sano, riesgo moderado e isquemia crítica.

Posteriormente, el dataset se dividió en conjuntos de entrenamiento y prueba mediante partición estratificada, con el fin de conservar la proporción original de clases en ambos subconjuntos. Esta decisión fue especialmente importante debido al desbalance presente en el problema.

La variable categórica Tipo_Dolor fue transformada mediante One-Hot Encoding, generando columnas binarias para cada categoría. Luego, se alinearon las columnas de entrenamiento y prueba para asegurar que ambos conjuntos mantuvieran la misma estructura. Por su parte, las variables continuas Troponina_T, Presion_Arterial y Edad fueron estandarizadas usando únicamente la media y desviación estándar del conjunto de entrenamiento, evitando fuga de información hacia el conjunto de prueba.

Finalmente, los datos fueron convertidos a arreglos de NumPy, dejando el pipeline listo para el entrenamiento de los modelos. En esta etapa se utilizaron principalmente `train_test_split`, `pd.get_dummies` y operaciones de escalamiento basadas en media y desviación estándar.

4. Implementación y comparación de modelos

En esta etapa se implementaron y compararon ocho modelos de regresión logística multiclase. Los primeros cuatro fueron desarrollados desde cero, mientras que los cuatro restantes se utilizaron como implementaciones de referencia mediante `scikit-learn`. El objetivo fue contrastar el comportamiento de una formulación manual basada en softmax y descenso de gradiente con el de una librería especializada.

4.1 Modelos desarrollados desde cero

Los modelos implementados manualmente fueron los siguientes:

- RegLog: regresión logística multiclase sin regularización
- RegLog-L1: regresión logística con penalización L1 (Lasso)
- RegLog-L2: regresión logística con penalización L2 (Ridge)
- RegLog-L1-L2: regresión logística con regularización Elastic Net

La implementación se construyó sobre una formulación multiclase con función softmax, utilizando como criterio de entrenamiento la entropía cruzada y como procedimiento de optimización el descenso de gradiente. En las variantes regularizadas, se incorporó un término adicional en la función de pérdida para penalizar la magnitud de los coeficientes, con el objetivo de controlar la complejidad del modelo y estudiar el efecto de la regularización sobre el desempeño y la interpretabilidad.

4.2 Implementaciones de referencia con scikit-learn

Como punto de comparación externa, se entrenaron cuatro modelos equivalentes utilizando scikit-learn:

- RegLog-sk
- RegLog-L1-sk
- RegLog-L2-sk
- RegLog-L1-L2-sk

Estas implementaciones permitieron contrastar los resultados obtenidos con los modelos desarrollados desde cero y evaluar diferencias tanto en el desempeño final como en la calidad de la optimización. En el caso de las variantes regularizadas, se ajustó el parámetro de regularización de acuerdo con la exploración realizada sobre el conjunto de datos corregido, adoptando finalmente $C = 1.0$ como valor representativo en las configuraciones de referencia.

4.3 Hiperparámetros base utilizados

Para los modelos desarrollados desde cero se utilizó como configuración base:

- `learning_rate` = 0.05
- `epochs` = 3000
- `lambda_reg` = 0.01 en las variantes regularizadas
- `l1_ratio` = 0.5 en Elastic Net

Estos valores se definieron como una configuración inicial razonable y posteriormente fueron contrastados mediante búsqueda de hiperparámetros. En particular, el valor `lambda_reg` = 0.01 se utilizó como una intensidad intermedia de regularización, suficiente para que la penalización tuviera un efecto visible sin volver excesivamente restrictivo al modelo.

4.4 Seguimiento del código en esta etapa

El código de esta sección, se organizó tomando como referencia la estructura técnica entregada en clases, en tres bloques principales; Primero, se definió la clase `LogisticRegressionScratch`, que implementa la lógica del modelo multiclase, incluyendo la función softmax, la pérdida de entropía cruzada, la incorporación de regularización y los métodos de predicción. Luego, se instanciaron y entrenaron los cuatro modelos scratch. Finalmente, se entrenaron los cuatro modelos equivalentes con scikit-learn, lo que permitió construir una comparación directa entre ambas familias de métodos.

GRUPO	MODELO	REGULARIZACIÓN
SCRATCH	RegLog	Ninguna
SCRATCH	RegLog-L1	L1
SCRATCH	RegLog-L2	L2
SCRATCH	RegLog-L1-L2	Elastic Net
REFERENCIA	RegLog-sk	Ninguna
REFERENCIA	RegLog-L1-sk	L1
REFERENCIA	RegLog-L2-sk	L2
REFERENCIA	RegLog-L1-L2-sk	Elastic Net

Tabla 2 Modelos implementados y tipo de regularización

5. Validación, robustez y sensibilidad de los modelos

El análisis de desempeño no se centró únicamente en ajustar parámetros, sino en evaluar la utilidad real de las predicciones en un contexto clínico crítico. Dado que el problema presenta desbalance de clases y errores de distinta gravedad, la validación se diseñó para reflejar no solo el rendimiento global del modelo, sino también su capacidad de detectar adecuadamente a los pacientes de mayor riesgo.

5.1 Selección de métricas de desempeño

En este problema, utilizar solamente accuracy no resulta suficiente, ya que la clase Sano domina el dataset y la clase Isquemia Crítica es minoritaria. En este contexto, un modelo podría alcanzar una accuracy relativamente alta y aun así fallar en la detección de pacientes graves. Por esta razón, se seleccionaron métricas más informativas y alineadas con la realidad clínica del problema.

Recall por clase

Dado el desbalance del problema, se reportó el **recall por clase** como una de las métricas principales de evaluación. Esta medida permite cuantificar qué proporción de pacientes reales de cada categoría fue correctamente detectada por el modelo. Su uso fue especialmente importante en la clase **isquemia crítica**, ya que un falso negativo en esta categoría representa el error más grave desde el punto de vista clínico.

En los resultados obtenidos, el recall de la clase crítica permitió diferenciar claramente entre modelos. Por ejemplo, mientras los modelos scratch base alcanzaron un recall de isquemia de **0.9**, el modelo RegLog-L1-sk logró un recall de **1.0**, detectando correctamente todos los pacientes críticos del conjunto de prueba. Del mismo modo, las variantes Weighted y

CostSensitive del Algoritmo 4 también alcanzaron recall crítico perfecto, confirmando la utilidad de mecanismos que reduzcan el sesgo hacia la clase mayoritaria.

F1-score ponderado

Además del recall por clase, se utilizó el **F1-score ponderado** como una medida de desempeño global en el contexto multiclase desbalanceado. Esta métrica resume el equilibrio entre precisión y sensibilidad, ponderando el aporte de cada clase según su frecuencia en el dataset.

Su uso permitió complementar la información entregada por la accuracy, evitando que el rendimiento global quedara excesivamente dominado por la clase mayoritaria. En los resultados, el mejor valor de F1 ponderado entre los modelos base fue obtenido por RegLog-L1-sk, con un valor de **0.9849**, mientras que entre las variantes del Algoritmo 4 destacó RegLog-L1-L2-CostSensitive, con un valor de **0.9900**.

Función de costo total asimétrica

Dado que no todos los errores tienen la misma gravedad clínica, se definió una función de costo total asimétrica para evaluar a los modelos de forma más realista. En particular, se asignó una penalización más alta al error de clasificar a un paciente con isquemia crítica como sano, ya que este representa el riesgo más severo del problema. En cambio, errores como clasificar a un paciente sano como de riesgo moderado recibieron una penalización menor.

Para ello, se utilizó la siguiente matriz de costos:

Clase real \ Predicción	Sano	Riesgo	Isquemia
Sano	0	1	4
Riesgo	2	0	6
Isquemia	10	5	0

Tabla 3 Matriz de costo asimétrica utilizada en la evaluación

El costo total se calculó sumando el valor correspondiente a cada predicción incorrecta en el conjunto de prueba. De esta manera, la métrica no solo considera cuántos errores comete el modelo, sino también qué tan graves son desde el punto de vista clínico.

En los resultados obtenidos, esta medida permitió distinguir con mayor claridad entre modelos con desempeños globales similares. Por ejemplo, RegLog alcanzó un costo total de **12**, mientras que RegLog-L1-sk redujo ese valor a **5**. Más aún, la variante RegLog-L1-L2-CostSensitive logró un costo total de **3**, mostrando que la incorporación explícita de sensibilidad al costo mejora la seguridad diagnóstica del modelo.

Matriz de confusión

Finalmente, se utilizaron matrices de confusión para visualizar cómo se distribuyen los aciertos y errores entre clases, lo que permite observar de forma directa si los pacientes críticos se confunden con sanos, con riesgo o si los errores se concentran en otras transiciones menos graves.

Resultados conjunto de los modelos

La comparación general de los ocho modelos mostró que la mejor formulación base de referencia fue **RegLog-L1-sk**, la cual alcanzó los mejores valores de desempeño entre los modelos estándar: alta accuracy, balanced accuracy elevada, recall perfecto en la clase isquemia crítica y el menor costo total asimétrico.

Por su parte, entre los modelos desarrollados desde cero, el mejor comportamiento base correspondió a **RegLog**, que logró un desempeño competitivo, aunque inferior al de las implementaciones de referencia. Esto es consistente con el hecho de que scikit-learn utiliza procedimientos de optimización más refinados y numéricamente más estables.

En términos generales, los resultados muestran que la evaluación basada en recall por clase y costo asimétrico fue más informativa que la sola accuracy, ya que permitió identificar con mayor claridad qué modelos eran clínicamente más seguros.

Modelo	Accuracy	Balanced Accuracy	Recall Sano	Recall Riesgo	Recall Isquemia	F1 Weighted	Costo Total
RegLog	0.9750	0.9313	0.9938	0.9000	0.9000	0.9747	12
RegLog-L1	0.9600	0.8979	0.9938	0.8000	0.9000	0.9587	18
RegLog-L2	0.9500	0.8757	0.9938	0.7333	0.9000	0.9476	22
RegLog-L1-L2	0.9500	0.8757	0.9938	0.7333	0.9000	0.9476	22
RegLog-sk	0.9800	0.9424	0.9938	0.9333	0.9000	0.9799	10
RegLog-L1-sk	0.9850	0.9757	0.9938	0.9333	1.0000	0.9849	5
RegLog-L2-sk	0.9800	0.9424	0.9938	0.9333	0.9000	0.9799	10
RegLog-L1-L2-sk	0.9800	0.9424	0.9938	0.9333	0.9000	0.9799	10

Tabla 4 Resultados finales de los ocho modelos evaluados

La tabla 3 resume el desempeño final de los ocho modelos evaluados. Se observa que la formulación con mejor comportamiento global fue **RegLog-L1-sk**, ya que alcanzó la mayor balanced accuracy, recall perfecto en la clase isquemia crítica y el menor costo total asimétrico. Entre los modelos desarrollados desde cero, el mejor desempeño base correspondió a **RegLog**, con resultados competitivos, aunque inferiores a los de las implementaciones de referencia.




Figura 3 Comparación de Balanced Accuracy entre los modelos evaluados

La Figura 3 refuerza lo observado en la tabla de resultados: el modelo RegLog-L1-sk fue el más sólido en términos de balanced accuracy, lo que indica una mejor capacidad de clasificación equilibrada entre las tres clases. En contraste, las variantes scratch regularizadas (RegLog-L1, RegLog-L2 y RegLog-L1-L2) mostraron un descenso más claro en esta métrica, lo que sugiere una mayor pérdida de sensibilidad sobre las clases minoritarias.

La matriz de confusión se utilizó para visualizar cómo se distribuyen los aciertos y errores entre las tres clases diagnósticas. A diferencia de métricas agregadas como accuracy o F1-score, esta representación permite identificar con claridad si los errores del modelo recaen sobre transiciones clínicamente más peligrosas, en particular cuando un paciente con **isquemia crítica** es clasificado en una categoría menos grave.




Figura 4 Matriz de confusión del modelo RegLog




Figura 5 Matriz de confusión del modelo RegLog-L1-sk

En el caso de **RegLog**, la matriz de confusión muestra un buen desempeño global, aunque aún persiste al menos un error sobre la clase crítica, lo que se refleja en un recall de isquemia de 0.9 y en un costo total mayor. En cambio, la matriz correspondiente a **RegLog-L1-sk** presenta una estructura de errores más favorable, ya que detecta correctamente todos los pacientes con isquemia crítica y concentra sus errores en confusiones menos severas entre las clases sano y riesgo. Esto confirma que, además de lograr mejores métricas globales, el modelo de referencia con regularización L1 presenta una distribución de errores clínicamente más segura.

5.2 Análisis de sensibilidad

Análisis de sensibilidad al volumen de datos

Con el fin de evaluar la robustez de los modelos desarrollados desde cero, se analizaron tres escenarios de volumen de datos: bajo, medio y alto. En todos los casos se mantuvo la misma proporción de clases, de manera que el estudio se concentrara en el efecto de la cantidad total de muestras y no en un cambio de distribución.

En términos generales, el volumen de datos influye directamente en la estabilidad del aprendizaje. Con una mayor cantidad de ejemplos, el modelo dispone de más información para estimar mejor sus parámetros y reducir la variabilidad del ajuste. En problemas clínicos desbalanceados, este efecto es especialmente importante, ya que la clase de mayor interés médico también es la menos frecuente y, por tanto, la más sensible a cambios en el tamaño muestral.

Los resultados muestran que el volumen modifica no solo el desempeño promedio, sino también la capacidad del clasificador para detectar pacientes críticos. En particular, el escenario de volumen medio entregó un equilibrio razonable entre recall de isquemia, balanced accuracy y costo total, mientras que el escenario alto produjo un aumento importante del costo total en varias formulaciones regularizadas, a pesar de mantener accuracies elevadas.

Volumen	n total	Modelo	Balanced Accuracy	Recall Isquemia	F1 Weighted	Costo Total
Bajo	300	RegLog	0.8889	1.0000	0.9458	6
Bajo	300	RegLog-L1	0.7778	0.6667	0.9283	11
Bajo	300	RegLog-L2	0.7778	0.6667	0.9283	11
Bajo	300	RegLog-L1-L2	0.7778	0.6667	0.9283	11
Medio	1000	RegLog	0.9313	0.9000	0.9747	12
Medio	1000	RegLog-L1	0.8979	0.9000	0.9587	18
Medio	1000	RegLog-L2	0.8757	0.9000	0.9476	22
Medio	1000	RegLog-L1-L2	0.8757	0.9000	0.9476	22
Alto	3000	RegLog	0.9208	0.8667	0.9746	40
Alto	3000	RegLog-L1	0.8475	0.7333	0.9549	75
Alto	3000	RegLog-L2	0.8505	0.7333	0.9551	74
Alto	3000	RegLog-L1-L2	0.8475	0.7333	0.9549	75

Tabla 5 Sensibilidad de los modelos scratch ante distintos volúmenes de datos

La Tabla 5 resume el desempeño de los modelos scratch bajo distintos escenarios de volumen de datos. Se observa que la cantidad de muestras influye de manera relevante sobre la balanced accuracy, el recall de isquemia y el costo total, especialmente en las formulaciones regularizadas.




Figura 6 Recall de Isquemia según volumen de datos

La Figura 6 muestra que el volumen de datos influye de forma importante en la detección de la clase crítica. En el escenario de bajo volumen, el modelo RegLog logró recall perfecto, mientras que las variantes regularizadas presentaron mayor dificultad. En el escenario alto, el recall de isquemia disminuyó en varias formulaciones, lo que sugiere que un mayor tamaño muestral no garantiza por sí solo un mejor comportamiento clínico si la estructura del problema y la regularización no se equilibran adecuadamente.




Figura 7 Balanced Accuracy según volumen de datos

La Figura 7 muestra que el escenario de volumen medio produjo, en general, el comportamiento más estable y equilibrado. En contraste, el escenario bajo afectó con fuerza a las variantes regularizadas, mientras que el escenario alto incrementó el costo total clínico en varias configuraciones, pese a mantener accuracies relativamente altas.

En conjunto, el análisis de sensibilidad al volumen mostró que el desempeño del clasificador no depende únicamente de tener más datos, sino también de cómo estos interactúan con el desbalance de clases y la regularización. Los resultados sugieren que, en este problema, el volumen medio ofreció un compromiso razonable entre estabilidad, sensibilidad clínica y costo total, mientras que los extremos del experimento introdujeron comportamientos menos favorables en algunas formulaciones.

Análisis de sensibilidad al solapamiento entre clases

Con el fin de evaluar la robustez de los modelos desarrollados desde cero, se analizó su comportamiento bajo distintos niveles de solapamiento entre clases. Para ello, se generaron escenarios de dificultad creciente, modificando la dispersión de las variables clínicas en el dataset sintético. Este procedimiento permitió estudiar cómo cambia el desempeño de los clasificadores cuando las fronteras entre las clases se vuelven menos nítidas.

En términos generales, el aumento del solapamiento hace que los pacientes de distintas categorías se parezcan más entre sí en el espacio de características, lo que dificulta la separación lineal y vuelve el problema más complejo. En este contexto, se espera una disminución del recall de la clase crítica, una reducción de la balanced accuracy y un aumento del costo total asimétrico.

En los resultados obtenidos, el incremento del solapamiento efectivamente deterioró el desempeño de los modelos scratch, especialmente en las clases minoritarias. Esto es consistente con el compromiso entre sesgo y varianza: cuando las clases se mezclan más, un modelo lineal puede volverse demasiado rígido para capturar adecuadamente la estructura del problema, aumentando el sesgo y reduciendo su capacidad discriminativa.

Overlap	Modelo	Balanced Accuracy	Recall Isquemia	F1 Weighted	Costo Total
Bajo	RegLog	0.9979	1.0000	0.9950	1
Bajo	RegLog-L1	0.9979	1.0000	0.9950	1
Bajo	RegLog-L2	0.9646	0.9000	0.9900	6
Bajo	RegLog-L1-L2	0.9646	0.9000	0.9900	6
Medio	RegLog	0.9313	0.9000	0.9747	12
Medio	RegLog-L1	0.8979	0.9000	0.9587	18
Medio	RegLog-L2	0.8757	0.9000	0.9476	22
Medio	RegLog-L1-L2	0.8757	0.9000	0.9476	22
Alto	RegLog	0.8736	0.9000	0.9428	23
Alto	RegLog-L1	0.8424	0.9000	0.9300	28
Alto	RegLog-L2	0.8313	0.9000	0.9239	30
Alto	RegLog-L1-L2	0.8424	0.9000	0.9300	28

Tabla 6 Sensibilidad de los modelos scratch ante distintos niveles de solapamiento

La Tabla 6 resume el comportamiento de los modelos scratch bajo distintos niveles de solapamiento entre clases. Se observa que, a medida que aumenta la dificultad del problema, disminuye la balanced accuracy y aumenta el costo total asimétrico, lo que indica una mayor dificultad para separar correctamente las clases en regiones clínicas ambiguas.




Figura 8 Costo total asimétrico según nivel de solapamiento entre clases

La Figura 7 muestra una tendencia creciente del costo total a medida que el problema se vuelve más difícil. Esto indica que, cuando las clases se mezclan más en el espacio de características, aumentan los errores del clasificador y, en particular, aquellos con mayor impacto clínico.




Figura 9 Recall de Isquemia según nivel de solapamiento entre clases

La Figura 8 muestra que el recall de isquemia se mantiene relativamente estable en este experimento, aunque el resto de las métricas se deteriora al aumentar el solapamiento. Esto sugiere que, aun cuando los modelos siguen detectando gran parte de los casos críticos, el

problema se vuelve menos separable en términos globales y aumentan las confusiones entre clases menos extremas.

En conjunto, la tabla y las figuras muestran que el aumento del solapamiento entre clases afecta negativamente la capacidad de discriminación de los modelos lineales. Aunque el recall de la clase crítica se mantiene relativamente alto, la balanced accuracy disminuye y el costo total aumenta, lo que refleja una pérdida de robustez global del clasificador en escenarios de mayor dificultad.

Búsqueda exhaustiva de hiperparámetros y fronteras de decisión

Con el fin de mejorar la configuración de los modelos desarrollados desde cero, se realizó una búsqueda exhaustiva de hiperparámetros mediante un procedimiento tipo *grid search*. En esta exploración se evaluaron distintas combinaciones de `learning_rate`, número de épocas y fuerza de regularización (`lambda_reg`), mientras que en el caso de Elastic Net se incorporó además el parámetro `l1_ratio`. El criterio de selección no se basó únicamente en accuracy, sino principalmente en Recall de Isquemia, Balanced Accuracy, F1-score ponderado y Costo Total, de manera coherente con la naturaleza clínica y desbalanceada del problema.

A partir de esta búsqueda se seleccionó la mejor configuración para cada uno de los cuatro modelos scratch. En términos generales, los resultados muestran que la regularización más fuerte no siempre conduce al mejor desempeño, y que en este problema la mejor configuración correspondió al modelo RegLog sin regularización, seguido de configuraciones suavemente regularizadas para L1, L2 y Elastic Net.

Además, se generaron fronteras de decisión en una proyección bidimensional del problema usando las variables Troponina T y Presión Arterial. Estas figuras no representan la totalidad del espacio de atributos, pero sí permiten visualizar cómo cambian las regiones de decisión de cada configuración seleccionada y cómo la regularización modifica la forma en que el modelo separa las clases.

Modelo	Learning Rate	Épocas	Lambda Reg	L1 Ratio
RegLog	0.10	3000	—	—
RegLog-L1	0.05	3000	0.001	—
RegLog-L2	0.05	3000	0.001	—
RegLog-L1-L2	0.05	3000	0.001	0.2

Tabla 7 Mejores configuraciones obtenidas en la búsqueda de hiperparámetros para los modelos scratch

La Tabla 7 resume las mejores configuraciones seleccionadas para cada modelo scratch después de la búsqueda exhaustiva de hiperparámetros. Se observa que las formulaciones regularizadas alcanzaron su mejor desempeño con una penalización relativamente baja (`lambda_reg` = 0.001), mientras que el modelo sin regularización obtuvo su mejor resultado con `learning_rate` = 0.10 y 3000 épocas de entrenamiento.




Figura 10 Frontera de decisión bidimensional del modelo RegLog




Figura 11 Frontera de decisión bidimensional del modelo RegLog-L1




Figura 12 Frontera de decisión bidimensional del modelo RegLog-L2




Figura 13 Frontera de decisión bidimensional del modelo RegLog-L1-L2

Estas figuras muestran una proyección bidimensional de las fronteras de decisión aprendidas por las mejores configuraciones de cada modelo scratch, utilizando las variables **Troponina T** y **Presión Arterial**. Aunque el problema original considera más atributos, esta visualización permite interpretar de manera cualitativa cómo cambia la separación entre clases bajo distintas formulaciones de regularización.

Las fronteras de decisión muestran que, aun dentro de una formulación lineal, la regularización modifica la posición relativa de las regiones asignadas a cada clase. En general, el modelo sin regularización presenta la frontera más flexible dentro de las limitaciones lineales del problema, mientras que las variantes con L1, L2 y Elastic Net tienden a generar separaciones más conservadoras. Estas diferencias ayudan a interpretar por qué algunas configuraciones ofrecen mejor balanced accuracy o menor costo total, especialmente cuando la separación entre riesgo e isquemia se vuelve más ambigua.

En conjunto, la búsqueda exhaustiva de hiperparámetros permitió seleccionar configuraciones más adecuadas para el problema clínico planteado, mientras que las fronteras de decisión facilitaron una interpretación cualitativa del efecto de la regularización sobre la separación entre clases. Esto permitió complementar el análisis cuantitativo con una visión más intuitiva del comportamiento de cada formulación scratch.

6. Compensación del sesgo por clase mayoritaria

En esta etapa se modificó la formulación del Algoritmo 4 (RegLog-L1-L2) con el objetivo de mitigar el sesgo hacia la clase mayoritaria Sano. Dado que el dataset presenta una distribución desbalanceada, los ejemplos de la clase sana dominan la función de pérdida y, en consecuencia, las actualizaciones de gradiente del modelo. Esto puede llevar a que el clasificador optimice preferentemente el desempeño sobre la clase más frecuente, relegando la detección adecuada de las clases minoritarias, especialmente Isquemia Crítica.

Para corregir este sesgo, se incorporó un mecanismo de ponderación de clases (class weighting) dentro de la función de optimización. Los pesos se definieron de manera inversamente proporcional a la frecuencia de cada clase, de modo que los errores cometidos sobre clases minoritarias generaran una contribución mayor en la pérdida total y en el gradiente. Bajo esta lógica, los ejemplos de la clase Isquemia reciben una influencia más fuerte en el proceso de entrenamiento que los ejemplos de la clase Sano.

Los resultados mostraron que esta modificación produjo una mejora importante respecto al modelo original RegLog-L1-L2. En particular, la variante RegLog-L1-L2-Weighted incrementó el recall de Isquemia de 0.9000 a 1.0000, elevó el recall de Riesgo de 0.7333 a 0.9667, aumentó la balanced accuracy de 0.8757 a 0.9806, y redujo el costo total asimétrico de 25 a 6. Esto indica que el mecanismo de ponderación de clases fue efectivo para disminuir el sesgo hacia la clase mayoritaria y mejorar la sensibilidad del modelo sobre las clases más importantes.

Modelo	Accuracy	Balanced Accuracy	Recall Sano	Recall Riesgo	Recall Isquemia	F1 Weighted	Costo Total
RegLog-L1-L2	0.9500	0.8757	0.9938	0.7333	0.9000	0.9476	25
RegLog-L1-L2-Weighted	0.9750	0.9806	0.9750	0.9667	1.0000	0.9755	6

Tabla 8 Efecto de la ponderación de clases sobre el Algoritmo 4

La Tabla 8 compara el desempeño del Algoritmo 4 original con su versión modificada mediante ponderación de clases. Se observa una mejora sustancial en las métricas asociadas a las clases minoritarias, especialmente en el recall de riesgo e isquemia, junto con una fuerte reducción del costo total asimétrico.




Figura 14 Efecto de la ponderación de clases sobre el Algoritmo 4

La figura muestra que la versión ponderada del Algoritmo 4 reduce de manera importante el costo total respecto al modelo original. Esta mejora refleja que el mecanismo de *class weighting* no solo incrementa la sensibilidad sobre las clases minoritarias, sino que además disminuye la frecuencia de errores clínicamente más costosos.

Reflexión sobre la magnitud de los gradientes

¿Cómo cambia la magnitud de los gradientes durante el entrenamiento al introducir estos pesos?

Al introducir pesos de clase en la función de optimización, la magnitud efectiva de los gradientes asociados a las clases minoritarias aumenta. En términos prácticos, esto significa que un error cometido sobre un paciente de Riesgo o Isquemia genera una actualización más intensa de los parámetros que un error cometido sobre un paciente Sano. Como consecuencia, el modelo deja de estar tan dominado por la clase mayoritaria y comienza a prestar mayor atención a ejemplos clínicamente más relevantes.

Desde el punto de vista del aprendizaje, esto desplaza el equilibrio del entrenamiento: los ejemplos minoritarios, que antes tenían poco impacto en la pérdida total, pasan a influir con más fuerza en la dirección del descenso de gradiente. Esta es precisamente la razón por la que el *class weighting* mejora el recall de las clases poco frecuentes.

¿Es suficiente este mecanismo por sí solo?

Aunque la ponderación de clases mejora de forma importante el comportamiento del modelo, **no es suficiente por sí sola para resolver completamente el problema del desbalance.**

Esto se debe a que la dificultad del problema no depende únicamente de la frecuencia de las clases, sino también de otros factores como el solapamiento entre regiones, la calidad de las variables simuladas y la capacidad del modelo para representar patrones complejos.

En otras palabras, el class weighting corrige parcialmente el sesgo inducido por la clase mayoritaria, pero no elimina por sí mismo la ambigüedad estructural del problema. Por esta razón, en las etapas posteriores del trabajo se incorporaron mecanismos adicionales, como sensibilidad explícita al costo, que permitieron reducir aún más los errores críticos.

Como conclusión, en conjunto, los resultados muestran que la ponderación de clases fue una estrategia efectiva para compensar el sesgo hacia la clase mayoritaria. La mejora simultánea en recall de las clases minoritarias, balanced accuracy y costo total confirma que este mecanismo permitió hacer al modelo más sensible a los pacientes de mayor riesgo, aunque no resuelve por sí solo todos los desafíos del problema desbalanceado.

7. Optimización de costos y minimización de errores críticos

En esta etapa se modificó nuevamente la formulación del Algoritmo 4 (RegLog-L1-L2) para incorporar de forma explícita la asimetría de costos dentro del aprendizaje y del proceso de decisión. El objetivo fue reducir la probabilidad de cometer errores clínicamente críticos, en particular el de clasificar a un paciente con isquemia crítica como sano, ya que este constituye el caso más peligroso del problema.

Para ello, se definió una matriz de costos explícita más severa que la utilizada en la evaluación general, asignando una penalización mucho mayor a los falsos negativos sobre la clase crítica. En particular, el error de clasificar a un paciente con isquemia como sano recibió una penalización máxima, siguiendo la lógica sugerida en la consigna de imponer una relación muy superior respecto al error inverso. Sobre esta base, se evaluaron tres variantes del Algoritmo 4: una versión con ponderación por clase (Weighted), una versión con sensibilidad explícita al costo durante el aprendizaje (CostSensitive) y una versión con decisión basada en costo esperado mínimo (DecisionSensitive).

La penalización utilizada en la optimización cost-sensitive quedó definida mediante una matriz de costos explícita. En particular, el error de clasificar a un paciente con isquemia crítica como sano recibió un costo de 50, mientras que el error inverso, es decir, clasificar a un paciente sano como isquemia, recibió un costo de 5. Esto implica una relación de penalización de 10:1, lo que permitió orientar el aprendizaje hacia la reducción de falsos negativos críticos.

Aunque la consigna sugería como ejemplo una relación 50:1, en esta implementación se utilizó una asimetría igualmente fuerte, suficiente para reflejar que los errores sobre la clase crítica deben ser tratados con mucha mayor severidad que los falsos positivos sobre pacientes sanos.

Los resultados mostraron que la mejor formulación fue RegLog-L1-L2-CostSensitive, la cual alcanzó Accuracy de 0.9900, Balanced Accuracy de 0.9868, Recall de Isquemia de 1.0000, F1 ponderado de 0.9900 y Costo Total de 3. Este resultado superó tanto al modelo original RegLog-L1-L2 como a las demás variantes modificadas, lo que indica que integrar la asimetría de costos directamente en el aprendizaje resultó más efectivo que modificar únicamente la regla de decisión final.

Modelo	Accuracy	Balanced Accuracy	Recall Sano	Recall Riesgo	Recall Isquemia	F1 Weighted	Costo Total
RegLog-L1-L2	0.9500	0.8757	0.9938	0.7333	0.9000	0.9476	25
RegLog-L1-L2-Weighted	0.9750	0.9806	0.9750	0.9667	1.0000	0.9755	6
RegLog-L1-L2-CostSensitive	0.9900	0.9868	0.9938	0.9667	1.0000	0.9900	3
RegLog-L1-L2-DecisionSensitive	0.9700	0.9472	0.9750	0.9667	0.9000	0.9707	14

Tabla 9 Comparación de variantes del Algoritmo 4 bajo sensibilidad al costo

La Tabla 9 resume el desempeño de las variantes del Algoritmo 4 al incorporar mecanismos explícitos de sensibilidad al costo. Se observa que la formulación CostSensitive logró el mejor equilibrio entre desempeño global y seguridad diagnóstica, al alcanzar recall perfecto en la clase crítica y el menor costo total asimétrico.




Figura 15 Comparación de variantes cost-sensitive del Algoritmo 4

La figura 15 compara el costo total entre la versión original del Algoritmo 4 y sus variantes modificadas. Se observa que la incorporación de sensibilidad explícita al costo reduce de forma importante los errores clínicamente más graves, siendo RegLog-L1-L2-CostSensitive la formulación con menor costo total.

Justificación técnica

Desde el punto de vista técnico, un modelo con **accuracy global inferior pero recall superior en la clase crítica** puede ser preferible porque la accuracy no distingue entre errores leves y errores graves. En un problema desbalanceado, un clasificador puede obtener una accuracy alta simplemente clasificando correctamente la mayoría de los pacientes sanos, aun cuando falle en la detección de pacientes con isquemia crítica.

En cambio, el **recall de la clase crítica** mide directamente la proporción de pacientes graves que fueron correctamente identificados. Por esta razón, en un sistema de apoyo diagnóstico resulta más importante minimizar los falsos negativos críticos que maximizar marginalmente la accuracy total. En este trabajo, las variantes Weighted y CostSensitive demostraron precisamente ese efecto: mejoraron la detección de la clase isquemia y redujeron de forma importante el costo total asimétrico.

Justificación ética

Desde una perspectiva ética, en un contexto médico no todos los errores tienen el mismo valor moral ni el mismo impacto sobre el paciente. Clasificar erróneamente a un paciente con **isquemia crítica** como **sano** puede retrasar una intervención urgente y comprometer seriamente su seguridad. En contraste, un falso positivo sobre un paciente sano puede generar exámenes adicionales, costos o ansiedad, pero en general no pone en peligro inmediato su vida.

Por esta razón, un modelo con **mayor sensibilidad sobre la clase crítica**, aunque presente una accuracy global algo menor, constituye una herramienta diagnóstica más segura y preferible. En términos prácticos, esto implica que es éticamente más aceptable asumir cierto aumento de falsos positivos si con ello se reducen los errores que podrían dejar sin tratamiento oportuno a pacientes realmente graves.

En conjunto, los resultados muestran que incorporar explícitamente la asimetría de costos dentro del aprendizaje permite orientar el clasificador hacia decisiones más seguras. La variante RegLog-L1-L2-CostSensitive fue la más efectiva, ya que combinó recall crítico perfecto, balanced accuracy elevada y el menor costo total entre todas las variantes del Algoritmo 4.

8. Análisis de importancia de atributos e interpretabilidad

Uno de los objetivos centrales de este trabajo fue no solo obtener un buen desempeño predictivo, sino también identificar qué variables dominan la decisión del modelo. En contextos clínicos, esta dimensión es especialmente importante, ya que permite interpretar qué biomarcadores y factores de riesgo están influyendo con mayor fuerza en la clasificación y si ese comportamiento resulta razonable desde el punto de vista médico.

Para este análisis se eligió la formulación RegLog-L1, ya que la regularización L1 favorece soluciones dispersas y, por tanto, facilita la selección de características. A diferencia de otras formulaciones, L1 tiende a reducir a valores muy cercanos a cero los coeficientes de variables con escasa contribución adicional, lo que permite distinguir con mayor claridad entre atributos dominantes y atributos descartados.

La importancia global de cada variable se calculó a partir de la magnitud promedio absoluta de sus coeficientes finales en las tres clases. Este criterio permitió resumir cuánto participa cada atributo en la decisión global del clasificador.

Los resultados mostraron que la variable claramente dominante fue Troponina_T, seguida por Presion_Arterial, Dolor_1 y Edad. En contraste, variables como Fibrilacion_V, Diabetes y varias categorías de dolor fueron reducidas prácticamente a cero por la penalización L1.

Este hallazgo es clínicamente razonable en el caso de Troponina_T, ya que se trata del biomarcador principal de daño miocárdico y, en consecuencia, la señal más fuerte para distinguir la clase de isquemia crítica. También resulta coherente que Presion_Arterial y Edad aporten información relevante, dado que ambas variables se asocian con estabilidad hemodinámica y severidad general del cuadro. La importancia observada para Dolor_1 sugiere que el modelo utiliza esa categoría como una señal útil para reconocer perfiles menos compatibles con cuadros isquémicos severos.

Un caso particularmente interesante fue Fibrilacion_V. Aunque en la simulación esta variable se generó con una fuerte asociación hacia la clase Isquemia Crítica, su importancia global en RegLog-L1 resultó prácticamente nula. Esto no significa necesariamente que la variable sea irrelevante desde el punto de vista clínico, sino que, dentro de esta formulación regularizada, su información fue considerada redundante frente a variables más dominantes, especialmente Troponina_T. En otras palabras, la relevancia clínica de un atributo no siempre coincide con su importancia estadística dentro de un modelo penalizado.

Atributo	Importancia Global
Troponina_T	1.508198
Presion_Arterial	0.392791
Dolor_1	0.324602
Edad	0.288474
Dolor_2	0.000552
Dolor_3	0.000397
Diabetes	0.000248
Dolor_4	0.000190
Fibrilacion_V	0.000167

Tabla 10 Importancia global de atributos según el modelo RegLog-L1

La Tabla 10 resume la importancia global de los atributos calculada a partir de la magnitud promedio absoluta de los coeficientes finales del modelo RegLog-L1. Se observa un predominio claro de Troponina_T, seguida a gran distancia por Presion_Arterial, Dolor_1 y Edad.




Figura 16 Importancia global de atributos en el modelo RegLog-L1

La figura 16 muestra la magnitud promedio absoluta de los coeficientes finales del modelo RegLog-L1. Se observa que Troponina_T domina ampliamente la decisión del clasificador,

seguida por Presion_Arterial, Dolor_1 y Edad, mientras que otros atributos son prácticamente anulados por la regularización.




Figura 17 Frecuencia de Fibrilación Ventricular por clase en el dataset sintético

La Figura 17 muestra que Fibrilacion_V sí fue simulada con una asociación fuerte hacia la clase crítica. Por ello, su baja importancia en RegLog-L1 no debe interpretarse como ausencia de relevancia clínica, sino como evidencia de que la regularización la consideró redundante frente a variables más dominantes, especialmente Troponina_T.

En conclusión en este análisis, las variables que dominaron la decisión del modelo fueron **Troponina_T**, **Presion_Arterial**, **Dolor_1** y **Edad**. Estas variables concentraron prácticamente toda la magnitud de los coeficientes finales del modelo RegLog-L1, lo que indica que el clasificador se apoya principalmente en ellas para distinguir entre pacientes sanos, en riesgo e isquemia crítica.

La regularización L1 ayudó a descartar atributos redundantes o de escasa contribución adicional, reduciendo sus coeficientes a valores casi nulos. Esto ocurrió en particular con Fibrilacion_V, Diabetes y varias categorías de dolor, lo que demuestra el rol de la penalización como mecanismo de selección de características y mejora de la interpretabilidad.

Preguntas de discusión a considerar

1. Sobre el desbalance: ¿Qué sucede con la frontera de decisión cuando se pasa de un modelo estándar a uno con Class Weighting?

Cuando se pasa de un modelo estándar a uno con Class Weighting, la frontera de decisión deja de estar tan influida por la clase mayoritaria y se desplaza en favor de las clases minoritarias. En este problema, eso significa que la región asignada a la clase Sano tiende a reducirse, mientras que las regiones correspondientes a Riesgo e Isquemia se expanden.

Desde un punto de vista geométrico, el movimiento físico de la frontera puede interpretarse como un desplazamiento alejándose de la clase minoritaria. Esto ocurre porque, al introducir pesos inversamente proporcionales a la frecuencia de cada clase, los errores cometidos sobre ejemplos minoritarios generan gradientes más grandes durante el entrenamiento. Como consecuencia, el modelo deja de optimizar principalmente para la clase Sano y comienza a ajustar su frontera para capturar mejor las regiones donde se encuentran Riesgo e Isquemia.

Esto es coherente con tus resultados: al comparar RegLog-L1-L2 con RegLog-L1-L2-Weighted, el recall de Riesgo aumentó de 0.7333 a 0.9667, el recall de Isquemia aumentó de 0.9000 a 1.0000, y el costo total disminuyó de 25 a 6. Estos cambios indican que la frontera efectivamente se volvió menos sesgada hacia la clase mayoritaria.

2. Sobre la regularización: En el análisis de importancia, ¿existieron variables cuya importancia fue reducida a cero por la penalización L1? ¿Tiene esto sentido clínico según los rangos típicos proporcionados?

Sí. En el análisis de importancia realizado con RegLog-L1, varias variables quedaron con importancia prácticamente nula, lo que indica que la penalización **L1** las redujo casi por completo. Entre ellas destacaron:

- Fibrilacion_V
- Diabetes
- Dolor_2
- Dolor_3
- Dolor_4

En cambio, las variables dominantes fueron:

- Troponina_T
- Presion_Arterial
- Dolor_1
- Edad

Desde el punto de vista estadístico, esto tiene sentido porque la regularización L1 favorece soluciones dispersas, es decir, conserva solo las variables que aportan información adicional clara y empuja hacia cero aquellas que resultan redundantes o poco informativas.

Desde el punto de vista clínico, la interpretación requiere más cuidado. En el caso de Troponina_T, su alta importancia es completamente coherente con los rangos típicos proporcionados, ya que se trata del biomarcador principal de daño miocárdico. También es razonable que Presion_Arterial y Edad mantengan importancia, porque ayudan a distinguir gravedad e inestabilidad clínica.

El caso de Fibrilacion_V es más discutible. En la simulación, esta variable sí fue generada con una fuerte asociación hacia la clase Isquemia Crítica, pero el modelo L1 igualmente la redujo a casi cero. Esto sugiere que, dentro de esta formulación, su señal fue considerada redundante frente a variables más dominantes, especialmente Troponina_T. Por tanto, sí tiene sentido desde el punto de vista del modelo, aunque no debe interpretarse como ausencia de valor clínico real.

3. Sobre la asimetría: Si aumentamos el costo de los falsos negativos al infinito, el modelo clasificaría a todos los pacientes como isquemia crítica. ¿Dónde reside el equilibrio óptimo entre la seguridad del paciente y la eficiencia de los recursos hospitalarios?

El equilibrio óptimo no se encuentra en eliminar completamente el riesgo de falsos negativos a cualquier costo, sino en lograr una combinación razonable entre alta seguridad clínica y uso eficiente de los recursos hospitalarios.

Si el costo de los falsos negativos sobre la clase crítica creciera al infinito, el modelo tendería a clasificar a casi todos los pacientes como Isquemia Crítica, ya que esa sería la forma más directa de evitar el error más grave. Sin embargo, esto produciría una gran cantidad de falsos positivos, lo que implicaría:

- sobreuso de exámenes complementarios,
- ocupación innecesaria de recursos de urgencia,
- aumento de costos hospitalarios,
- y disminución de la utilidad práctica del sistema.

Por tanto, el equilibrio óptimo reside en una región donde el Recall de Isquemia sea muy alto, pero sin que ello implique transformar casi todos los casos en urgencias críticas. En otras palabras, se debe privilegiar la detección de pacientes graves, pero manteniendo una precisión suficiente para que el sistema siga siendo útil y operativamente sostenible.

En tus resultados, la variante RegLog-L1-L2-CostSensitive parece acercarse a ese equilibrio, ya que logró Recall de Isquemia = 1.0000, Balanced Accuracy = 0.9868 y Costo Total = 3, sin caer en una degradación del desempeño global. Esto sugiere que es posible aumentar la

seguridad diagnóstica sin convertir el modelo en una herramienta que sobrediagnostique de manera masiva.

4. Comparación scikit-learn versus from scratch: ¿Hubo diferencias significativas en los tiempos de convergencia o en los resultados finales entre sus implementaciones y las de la librería? Especifique posibles causas.

Sí, hubo diferencias tanto en los resultados finales como, de manera esperable, en la convergencia entre las implementaciones desarrolladas desde cero y las de scikit-learn.

En términos de desempeño final, los modelos de referencia de scikit-learn superaron a las implementaciones scratch. El mejor ejemplo fue RegLog-L1-sk, que alcanzó:

- Accuracy = **0.9850**
- Balanced Accuracy = **0.9757**
- Recall de Isquemia = **1.0000**
- Costo Total = **5**

En cambio, el mejor modelo scratch base (RegLog) obtuvo:

- Accuracy = **0.9750**
- Balanced Accuracy = **0.9313**
- Recall de Isquemia = **0.9000**
- Costo Total = **12**

Estas diferencias son consistentes con el hecho de que scikit-learn utiliza optimizadores más robustos y procedimientos numéricos más refinados que un descenso de gradiente manual.

Las posibles causas son:

1. Optimizadores más avanzados: scikit-learn emplea solvers especializados, más eficientes y estables que una implementación manual simple basada en descenso de gradiente.
2. Mejores criterios de parada: Mientras la implementación scratch usa un número fijo de épocas, la librería incorpora criterios internos de convergencia, tolerancias numéricas y control de iteraciones más finos.
3. Mayor estabilidad numérica: Las implementaciones de librería suelen manejar mejor problemas de escala, estabilidad en softmax y regularización.
4. Ajuste más efectivo de la regularización: En scikit-learn, la calibración de hiperparámetros como C permitió encontrar configuraciones más adecuadas, especialmente en RegLog-L1-sk.

En conclusión, las implementaciones scratch fueron valiosas para comprender el funcionamiento interno del algoritmo y el efecto de la regularización, pero las implementaciones de scikit-learn mostraron mejor rendimiento práctico debido a optimizadores más robustos, mejores criterios de convergencia y mayor estabilidad computacional.

Declaración de uso de herramientas de Inteligencia Artificial

En la elaboración de esta tarea se utilizó ChatGPT como herramienta de apoyo para orientar el desarrollo del trabajo, incluyendo la estructuración del código, la explicación de conceptos, la revisión de consistencia entre secciones, la interpretación de resultados y la redacción del informe final. En particular, la herramienta fue utilizada como apoyo guiado en la construcción y ajuste de partes del código, así como en la organización metodológica del análisis.

No obstante, la ejecución del código, la revisión de resultados, la detección y corrección de errores, la selección de configuraciones, la interpretación final y la decisión sobre los contenidos incluidos en la entrega fueron realizadas por el autor. Por ello, la herramienta de IA se utilizó como apoyo académico y técnico, pero no reemplazó la responsabilidad personal sobre el desarrollo ni sobre la versión final del trabajo.